

目标导向多模态情感分类的复现实证研究

——以 RethinkingTMS C (EMNLP 2023 Findings) 为例的独立分析

简相彪

2026 年 8 月

摘要

目标导向多模态情感分类 (Target-oriented Multimodal Sentiment Classification, TMS C) 要求模型结合文本与图像判断推文中指定目标实体的情感极性。RethinkingTMS C (Ye et al., 2023) 在 Twitter15 与 Twitter17 上系统比较了文本/图像单模态与多种多模态融合架构,发现现有系统主要依赖文本模态,图像带来的增益十分有限。本文以该工作为对象,完成三方面工作:(1) 代码级可运行性验证,确认数据读取、特征构造、单模态与多模态模型的前向/反向传播在无 GPU 环境下亦可跑通,并整理出面向 GPU 服务器的完整复现脚本包;(2) 基于作者随仓库公开的 220 组实验结果 (2 数据集 $\times$ 22 模型 $\times$ 5 种子) 进行系统再分析,包括均值/方差、种子稳定性、5 种子多数投票集成、相对文本基线的纠正/恶化统计、混淆矩阵与逐类指标;(3) 对原始数据进行统计,并对全部模型都预测错误的困难样本进行挖掘。结果表明:纯视觉模型远弱于文本模型;多数多模态模型相对 BERT 的 F1 提升不足 1 个百分点甚至下降;种子随机性对部分模型 (如 Faster2Bert) 影响极大 (准确率跨度最高达 17.7 个百分点);5 种子投票集成能在绝大多数模型上带来稳定增益 (最高 +7.7/+17.7 个 F1 百分点);负面情感与隐含/反讽表达是当前方法最主要的错误来源。上述发现为 TMS C 任务的数据建设、模型设计与评测协议提供了可操作的参考。

关键词: 多模态情感分类; 目标导向; 复现研究; BERT; 视觉编码器; 种子稳定性

1 引言

社交媒体中的一条推文往往同时包含文字与配图，而用户对推文中某个具体实体（如某位明星、某支球队）的情感态度，可能与整条推文的情感并不一致。为此，Yu 和 Jiang (2019) 提出目标导向多模态情感分类 (TMSC) 任务：给定文本、图像以及文本中的目标实体，判断该实体被表达的情感极性（负面/中性/正面），并构建了 Twitter15 与 Twitter17 两个英文数据集。此后，大量工作围绕视觉编码器与跨模态融合模块展开，方法日趋复杂，但两个数据集上的 F1 长期停留在 70% 左右，进步缓慢。

RethinkingTMSC (Ye et al., 2023) 对这一现象进行了实证剖析。作者固定文本编码器为 BERT (Devlin et al., 2019)，分别采用 ResNet-152 (He et al., 2016)、ViT-base (Dosovitskiy et al., 2021) 与 Faster R-CNN (Ren et al., 2015) 作为视觉编码器，在每种编码器下构建单模态基线以及多种融合变体，共 22 个模型 $\times$ 5 个随机种子，在两个数据集上进行统一评测。其核心结论是：图像模态的信息增益有限，多数目标的情感仅凭文本即可判定，因此简单而稳定的文本模型已经具有很强的竞争力。

本文并不是对原文的翻译，而是一次“复现 + 再分析”的独立实证研究，贡献如下：

1. **复现工程**：逐行核查官方代码，完成 CPU 环境下的代码级冒烟验证，识别出若干影响复现的工程问题（硬编码路径、脚本工作目录、预训练权重路径、PyPI 依赖缺失等），并提供面向 GPU 服务器的一键复现脚本包（`repro/`）。
2. **统计再分析**：对作者公开的 220 组结果重新聚合，给出均值 $\pm$ 标准差、模型排序、种子方差；新增 5 种子多数投票集成分析，发现集成几乎总是带来正收益。
3. **错误分析**：基于逐样本预测输出，计算混淆矩阵、逐类指标、相对文本基线的“纠正/恶化”样本数、按目标长度的错误率分层，并挖掘出全部 22 个模型均预测错误的困难样本，指出讽刺、反讽与隐含情感是主要失败模式。
4. **数据观察**：给出两个数据集在标签分布、图片共享程度、目标长度等方面的量化统计，并结合模型表现讨论“图像何时有用”。

2 任务定义与基准方法

2.1 任务定义

给定推文文本 $X = \{x_1, \dots, x_n\}$ 、文本中指定的目标实体 t （在文本中以占位符 $\$T\$$ 出现）以及配图 I ，TMSC 的目标是预测标签 $y \in \{\text{负面}, \text{中性}, \text{正面}\}$ 。评测指标为准确率（Acc）与宏平均 F1（Macro-F1），与原文一致。

2.2 模型体系

官方代码将模型按视觉编码器分为三组，每组内包含单模态基线与多种融合结构：

- **文本基线 BERT**：以 `bert-base-uncased` 为文本编码器，将句子与目标拼接为 [CLS] 句子 [SEP] 目标 [SEP] 的输入形式（即 Yu 和 Jiang, 2019 的 mBERT 设定），仅利用文本。
- **纯视觉模型**：ResNet-152（49 个区域 $\times$ 2048 维）、ViT-base（197 个 patch 向量）、Faster R-CNN（36 个区域 $\times$ 2048 维，Visual Genome 预训练）。
- **融合模型**：简单拼接类（ResBert / VitBert / FasterBert）、双线性张量融合 TFN（Zadeh et al., 2017）变体（ResBertTFN / VitBertTFN / FasterBertTFN）、MBERT 类（Res2Bert、Bert2Res、Res22Bert 及其 Vit/Faster 对应物）以及注意力类（ResBertAtt / VitBertAtt / FasterBertAtt）。

2.3 统一训练与评测协议

全部实验采用统一设置：8 个 epoch、batch size 32、学习率 2×10^{-5} 、5 个随机种子（0/42/199/2022/11122）；每轮在开发集上评测，按开发集准确率保存最优检查点，训练结束后加载最优检查点在测试集上评测；测试结果写入 `eval_results.txt`。损失函数为广义交叉熵（GCELoss， $q = 0$ 时退化为标准交叉熵），优化器为带线性 warmup 的 BertAdam。图像侧在特征构造阶段进行随机裁剪与水平翻转增强。

3 数据集分析

表 1 给出两个数据集的统计结果。Twitter15 的标签分布严重偏向中性（约 59%），而 Twitter17 相对均衡。两个数据集中，每条推文的目标平均只有约 1.6 个词，文本平均约 16 个词。一个值得注意的差异是**图片共享程度**：Twitter15 全部 5338 个样本对应 3502 张去重图片（38% 的图片被 2 个及以上样本共用），Twitter17 全部 5972 个样本对应 2908 张图片（66.5% 的图片被 2 个及以上样本共用）。即 Twitter17 中“同图多目标、多情感”的情况更普遍，图片与目标之间的关系更复杂，也更考验模型对目标与图像内容的对齐能力。

表 1: Twitter15 / Twitter17 数据集统计

数据集	划分	样本数	负面(%)	中性(%)	正面(%)	去重图片	平均每图样本	目标平均词数
Twitter15	train	3179	11.6	59.2	29.2	—	—	1.66
Twitter15	dev	1122	13.3	59.7	27.0	—	—	1.68
Twitter15	test	1037	10.9	58.5	30.6	—	—	1.68
Twitter15	全部	5338	—	—	—	3502	1.52	—
Twitter17	train	3562	11.7	46.0	42.3	—	—	1.65
Twitter17	dev	1176	12.2	44.0	43.8	—	—	1.62
Twitter17	test	1234	13.6	46.4	40.0	—	—	1.59
Twitter17	全部	5972	—	—	—	2908	2.05	—

注：多数类基线（全部预测中性）在 Twitter15 / Twitter17 测试集上的准确率分别为 58.53% 与 46.43%。文本平均约 16 词，未列入表中。




图 1: 两个数据集的标签分布（负面/中性/正面占比）

4 复现设置与可行性

4.1 本机环境与限制

本文的代码级验证在本机（Windows, CPU-only, torch 1.10.0+cpu, transformers 4.22.1）完成。经核查，完整训练复现需要的条件中：推文图片数据与预训练权重均已就绪（原始 IJCAI2019 数据集解压于 `data/twitter2015_images/` 与 `data/twitter2017_images/`，经核对与 tsv 的 ImageID 完全对应，Twitter15 3502 张、Twitter17 2908 张、缺失 0 张，并已整理到官方要求的 `data/<数据集>/images/`；ResNet-152 权重位于 `Code/resnet/resnet152.pth`，Faster R-CNN 权重位于 `Code/faster_rcnn/models/faster_rcnn_res101_vg.pth`）。本机仍不具备的条件是：（1）NVIDIA GPU（22 模型 $\times$ 2 数据集 $\times$ 5 种子共 220 次 BERT 级微调，CPU 上不现实）；（2）BERT/ViT 权重需首次运行时联网从 Hugging Face 下载（本机缓存为空、网络受限）。

因此，本文采取“代码冒烟验证 + 作者公开结果再分析 + 服务器复现包”三管齐下的策略：（1）在 CPU 上验证官方代码链路可运行；（2）对作者随仓库公开的 220 组测试结果（`output/`，即论文报告结果）做独立的统计与错误分析；（3）提供 `repro/` 一键脚本包，供在租用 GPU 服务器上完成真正的训练复现，复现完成后可将结果与本文表格对照。

4.2 代码级冒烟验证

为了确认官方代码并非“纸面可运行”，我们编写了 `analysis/smoke_test.py`：在无预训练权重、无 GPU 的条件下，用随机图像张量与随机初始化的微型 BERT（2 层、`hidden=64`）走通完整链路，并额外用真实推文图片验证图片加载路径，结果如下：

- Tsv 读取与 `AbmsaProcessor` 数据解析正常，8 条开发集样本全部成功构造 `MMInputFeatures`（含目标序列与 $3 \times 224 \times 224$ 图像特征）；
- BERT 前向/反向 + BertAdam 两步训练正常（`loss` ≈ 1.10 ），梯度正常传播；
- BERT 推理输出形状（`batch, 3`）正确；
- 多模态模型 `Res22Bert`（文本-图像交叉注意力）前向/反向正常（`loss` ≈ 1.06 ）；
- 真实推文图片经 ResNet 路径的随机裁剪、归一化后输出形状正确（ $3 \times 224 \times 224$ ）。

上述结果说明官方代码的主链路（数据 $\rightarrow$ 特征 $\rightarrow$ 训练 $\rightarrow$ 推理 $\rightarrow$ 图片加载）可以执行；真正影响完整复现的只是算力与预训练权重等外部资源，而非代码本身。

4.3 结果口径说明

第 5 节的定量结果基于作者随仓库公开的 `output/`（论文报告结果）：每个模型在每个数据集上有 5 个种子的 `eval_results.txt`。我们以均值 $\pm$ 标准差呈现，并新增了原文未报告的投票集成、纠正/恶化与分层错误率分析。待服务器复现完成后，可将 `repro/collect_results.py` 生成的 `results_summary.csv` 与本文表 2、表 3 直接对比。

5 结果与实证分析

5.1 全模型结果

表 2 与表 3 分别给出两个数据集上 22 个模型的 5 种子均值 $\pm$ 标准差，图 2 为可视化。所有数值均为百分比。

表 2: Twitter15 测试集结果 (5 种子均值 $\pm$ 标准差, %)

模型	视觉编码器	Acc	Macro-F1	最佳种子 F1
Bert	—	76.72 $\pm$ 1.29	71.19 $\pm$ 2.45	73.30
ResNet	ResNet-152	57.65 $\pm$ 1.11	32.52 $\pm$ 2.97	35.51
Vit	ViT-base	59.65 $\pm$ 1.27	31.25 $\pm$ 3.04	34.03
FasterRCNN	Faster R-CNN	55.97 $\pm$ 1.22	35.72 $\pm$ 6.07	42.45
ResBert	ResNet-152	75.29 $\pm$ 0.50	68.71 $\pm$ 1.50	70.41
ResBertTFN	ResNet-152	74.19 $\pm$ 1.05	68.92 $\pm$ 0.64	69.71
Res2Bert	ResNet-152	75.18 $\pm$ 1.85	67.77 $\pm$ 5.38	70.31
Bert2Res	ResNet-152	77.13 $\pm$ 1.49	71.48 $\pm$ 2.12	74.79
Res22Bert	ResNet-152	77.32 $\pm$ 0.70	72.06 $\pm$ 0.90	72.73
ResBertAtt	ResNet-152	76.03 $\pm$ 1.08	70.57 $\pm$ 2.67	72.89
VitBert	ViT-base	76.22 $\pm$ 1.01	70.37 $\pm$ 1.62	72.77
VitBertTFN	ViT-base	73.44 $\pm$ 0.87	67.46 $\pm$ 1.62	69.38
Vit2Bert	ViT-base	75.12 $\pm$ 1.13	69.40 $\pm$ 1.55	71.28
Bert2Vit	ViT-base	77.11 $\pm$ 0.49	71.91 $\pm$ 0.47	72.18
Vit22Bert	ViT-base	76.70 $\pm$ 0.84	71.67 $\pm$ 1.62	73.56
VitBertAtt	ViT-base	75.08 $\pm$ 0.46	68.94 $\pm$ 0.93	69.89
FasterBert	Faster R-CNN	75.45 $\pm$ 0.82	69.78 $\pm$ 1.37	71.26
FasterBertTFN	Faster R-CNN	72.09 $\pm$ 0.74	66.77 $\pm$ 1.16	68.53
Faster2Bert	Faster R-CNN	70.82 $\pm$ 3.34	57.94 $\pm$ 6.50	65.13
Bert2Faster	Faster R-CNN	77.36 $\pm$ 0.42	71.69 $\pm$ 0.41	72.11
Faster22Bert	Faster R-CNN	76.57 $\pm$ 0.51	70.88 $\pm$ 0.99	72.06
FasterBertAtt	Faster R-CNN	76.08 $\pm$ 0.99	70.08 $\pm$ 1.53	71.34

5.2 单模态 vs 多模态：图像增益有限且不稳定

三个纯视觉模型 (ResNet / ViT / Faster R-CNN) 在两个数据集上的 Macro-F1 仅为 31.3–54.1%，远低于文本基线 BERT (65.7–71.2%)，与原文“模型主要依赖文本”的结论一致。

再看多模态融合模型相对 BERT 的差距：

表 3: Twitter17 测试集结果 (5 种子均值 $\pm$ 标准差, %)

模型	视觉编码器	Acc	Macro-F1	最佳种子 F1
Bert	—	68.04 $\pm$ 0.45	65.66 $\pm$ 0.39	66.10
ResNet	ResNet-152	57.80 $\pm$ 1.11	51.98 $\pm$ 1.38	53.11
Vit	ViT-base	59.53 $\pm$ 1.07	54.08 $\pm$ 0.88	55.39
FasterRCNN	Faster R-CNN	56.18 $\pm$ 0.95	49.88 $\pm$ 1.91	52.50
ResBert	ResNet-152	67.93 $\pm$ 0.62	65.32 $\pm$ 0.59	65.91
ResBertTFN	ResNet-152	66.66 $\pm$ 1.35	63.99 $\pm$ 1.81	65.66
Res2Bert	ResNet-152	68.07 $\pm$ 0.65	65.18 $\pm$ 1.65	66.24
Bert2Res	ResNet-152	69.37 $\pm$ 0.41	66.85 $\pm$ 0.88	67.99
Res22Bert	ResNet-152	68.41 $\pm$ 1.13	66.39 $\pm$ 1.55	68.19
ResBertAtt	ResNet-152	68.01 $\pm$ 1.07	65.41 $\pm$ 1.78	66.95
VitBert	ViT-base	67.94 $\pm$ 0.79	66.17 $\pm$ 0.88	67.07
VitBertTFN	ViT-base	65.46 $\pm$ 1.86	62.02 $\pm$ 1.56	63.88
Vit2Bert	ViT-base	67.52 $\pm$ 1.19	64.49 $\pm$ 1.63	66.13
Bert2Vit	ViT-base	69.14 $\pm$ 0.58	66.96 $\pm$ 0.76	67.85
Vit22Bert	ViT-base	69.16 $\pm$ 0.19	67.25 $\pm$ 0.63	67.83
VitBertAtt	ViT-base	67.52 $\pm$ 0.65	65.55 $\pm$ 0.39	66.01
FasterBert	Faster R-CNN	67.60 $\pm$ 1.28	64.74 $\pm$ 1.90	67.23
FasterBertTFN	Faster R-CNN	66.34 $\pm$ 1.63	62.96 $\pm$ 2.34	64.81
Faster2Bert	Faster R-CNN	60.31 $\pm$ 7.18	54.51 $\pm$ 7.90	61.06
Bert2Faster	Faster R-CNN	68.43 $\pm$ 0.72	66.44 $\pm$ 1.23	68.39
Faster22Bert	Faster R-CNN	69.51 $\pm$ 0.69	67.50 $\pm$ 0.42	67.95
FasterBertAtt	Faster R-CNN	68.09 $\pm$ 1.23	66.12 $\pm$ 1.38	67.81




图 2: 两个数据集上各模型 Macro-F1 的均值与标准差（按视觉编码器着色）

- **Twitter15**: 21 个融合模型中有 16 个的 F1 均值低于 BERT；仅 Res22Bert (+0.87)、Bert2Vit (+0.72)、Bert2Faster (+0.50)、Vit22Bert (+0.48) 等 5 个模型取得微弱正增益，最高也不足 1 个 F1 百分点。
- **Twitter17**: 21 个融合模型中有 13 个低于 BERT；Faster22Bert (+1.84)、Vit22Bert (+1.59)、Bert2Vit (+1.31)、Bert2Res (+1.19) 等取得正增益，幅度同样有限。

值得注意的是，**Twitter17** 上的正增益模型数量更多、幅度更大。结合第 3 节的数据观察，Twitter17 的图片共享程度更高、标签分布更均衡，图像内容与目标情感的相关性更强，这为“图像何时有用”提供了一个数据层面的解释：当图像与目标/情感的关系更紧密时，多模态融合才能带来可观测的收益。

5.3 种子稳定性：部分模型“一次跑定生死”

按模型计算 5 个种子准确率的极差 (max-min)：

- Twitter15 上，Faster2Bert 极差 8.4 个百分点 (65.09–73.48)，Res2Bert 4.5，其余模型大多在 1–3 个百分点之间；
- Twitter17 上，Faster2Bert 极差高达 **17.7** 个百分点 (48.38–66.05)，FasterBertTFN / VitBertTFN 等 TFN 类模型也超过 4 个百分点；
- 从标准差看，Twitter15 的 Res2Bert、Faster2Bert 的 F1 标准差分别达 5.4 与 6.5 个百分点，远高于同组其他模型。

这说明：（1）在 22 个模型中，个别模型（尤其 Faster2Bert 与部分 TFN 变体）的训练极不稳定，单次运行的结果不足以代表模型真实水平；（2）论文若只报告“最佳种子”或单次结果，可能会高估/低估某些方法；（3）评测协议应报告多次种子的均值±标准差，这也是本文建议后续研究采用的报告方式。

5.4 新增分析：5 种子多数投票集成几乎总是“稳赚”

原文未报告多种子集成。本文利用作者公开的 5 组预测做多数投票，得到以下发现（图 3、表 4）：

- Twitter15：22 个模型中 20 个的投票 F1 $\geq$ 单种子（seed=0）F1；增益最大的三个模型为 ResBertAtt（+7.71）、VitBertTFN（+5.66）、Vit22Bert（+5.19），单位均为 F1 百分点；明显回退的只有本身就不稳定的 Faster2Bert（-5.25）与纯视觉 FasterRCNN（-8.04）。
- Twitter17：21/22 个模型投票不劣于单种子；Faster2Bert 因种子极不稳定，从投票中获益最多（+16.32）；投票后 Twitter17 的最佳模型为 Bert2Res（F1=68.71%），超过任何单种子结果。
- 集成后 BERT 本身也从 66.02/73.19 提升到 66.76/73.37（Twitter17/Twitter15），说明多数错误来自随机性而非系统性偏差，简单集成即可稳定获得收益。

表 4：重点模型：单种子 vs 5 种子投票集成（Macro-F1，%）

数据集	模型	seed=0	投票集成	差值
Twitter15	Bert	73.19	73.37	+0.18
Twitter15	Vit22Bert	69.20	74.39	+5.19
Twitter15	ResBertAtt	66.10	73.81	+7.71
Twitter15	Faster2Bert	65.13	59.88	-5.25
Twitter17	Bert	66.02	66.76	+0.75
Twitter17	Bert2Res	65.84	68.71	+2.87
Twitter17	Faster2Bert	41.38	57.71	+16.32




图 3：5 种子投票集成与单种子（seed=0）的 Macro-F1 对比（对角线上方代表集成更好）

5.5 新增分析：多模态相对文本基线的“纠正/恶化”

将每个多模态模型（seed=0）的预测与 BERT 逐样本比较，统计两类样本数：BERT 错而多模态对（纠正）、BERT 对而多模态错（恶化），结果见图 4。




图 4：多模态模型相对文本基线 BERT 的净纠正样本数（纠正-恶化，seed=0）

- **Twitter15**: 21 个多模态模型全部净效应 ≤ 0 ，即图像信息的引入总体上“弊大于利”：例如 Res22Bert 虽总 F1 略高于 BERT，但逐样本上仍为 -2（纠正 58 / 恶化 60）；TFN 类模型恶化明显（VitBertTFN -51、FasterBertTFN -58）。
- **Twitter17**: Bert2Res (+8)、FasterBertAtt (+6)、Vit22Bert (+6)、Faster22Bert (+2) 等模型净效应为正，说明在图片与目标关联更强的 Twitter17 上，图像确实能“救回”一部分文本无法判定的样本；但多数模型仍为净负。
- 两个数据集上，BERT 与多模态模型的预测高度一致（逐模型统计：Twitter15 上约 69-72% 的样本两者同时正确、约 16-17% 同时错误；Twitter17 上约 60-61% 同时正确、约 23-24% 同时错误），真正不同的样本仅占约 10%，这也是为什么总体 F1 差距很小。

5.6 混淆矩阵与逐类指标

图 5 与图 6 给出文本基线 BERT 与各数据集最优多模态模型（Twitter15 的 Res22Bert、Twitter17 的 Bert2Res）在 seed=0 下的混淆矩阵。两类模型均呈现相同模式：

- Twitter15 上：中性类最易（F1=82.3），正面类次之（72.7），负面类最难（64.6）；
- Twitter17 上：正面类最易（F1=71.1），中性类次之（69.2），负面类最难（57.7）；
- 负面类在两个数据集上始终最难，因为负面情感常以反讽、隐晦方式表达；

- 错误主要发生在“负面 ↔ 中性”与“正面 ↔ 中性”之间，极少出现“负面 ↔ 正面”的极性反转。

纯视觉模型则出现**类别坍塌**：ResNet / ViT / Faster R-CNN 几乎不预测负面类（负面类召回率极低甚至为 0），这也是其 F1 极低的原因——视觉模型在该任务上无法独立建模负面情感。




图 5: Twitter15: 文本基线 BERT 与最优多模态模型 (Res22Bert) 的混淆矩阵 (seed=0, 行归一化)




图 6: Twitter17: 文本基线 BERT 与最优多模态模型 (Bert2Res) 的混淆矩阵 (seed=0, 行归一化)

5.7 错误分层与困难样本

按目标词数对 BERT (seed=0) 的错误率分层 (表 5):

表 5: 按目标词数的错误率 (BERT, seed=0)

数据集	目标 1 词	目标 2 词	目标 3+ 词
Twitter15	24.1%	21.7%	18.3%
Twitter17	29.1%	33.4%	35.8%

两个数据集上目标长度与错误率的关系方向相反: Twitter15 上目标越长错误越少,

Twitter17 上目标越长错误越多。一种可能的解释是：Twitter17 的长目标多为球队/联盟等集体实体（如 Premier League），其情感更依赖外部知识与上下文；而 Twitter15 的长目标常为专有名词，拼写特征本身即可提供较强的判别信号。该假设有待更大规模验证。

进一步，我们统计了每个测试样本被多少个模型（22 个模型 $\times$ seed=0）预测错误，挖掘出全部 22 个模型都预测错误的样本（表 6）。这些样本几乎都是需要反讽理解或隐含常识的推文。

表 6: 全部 22 个模型均预测错误的代表性样本

数据集	真实标签	推文（节选）	失败原因分析
Twitter15	负面	Meet the Michael Jackson impersonator who wants to heal \$T\$	反讽：表面“治愈”实为负面
Twitter15	正面	Views from \$T\$. No filter	隐含情感：需结合图片才知是赞美风景
Twitter15	负面	Coretta Scott King with Robert amp \$T\$ after husband's assassination	背景常识缺失
Twitter17	负面	Meek Mill beats \$T\$, Kendrick Lamar , Future to win Top Rap Album...	目标区分：同一句中多个实体，仅被提名者情感为负
Twitter17	中性	Me , along with a couple of friends — James Franco and \$T\$ — on the set...	中性陈述但易被误判为正面
Twitter17	负面	@ \$T\$ Congrats ! You have went full Harry Reid stupid !	反讽式祝贺

这些样本说明：当前 TMSC 模型的瓶颈不在“看不见图片”，而在语言层面的反讽、隐含情感与实体区分。仅提升视觉编码器或融合模块难以解决这类问题，需要更强的语言理解、常识推理或专门的训练数据。

5.8 数据层面的补充观察

- Twitter15 测试集中有 113 个负面样本（10.9%），模型负面类 F1 约 64%；Twitter17 负面样本 168 个（13.6%），负面类 F1 约 58–62%——负面样本少且难，是 F1 上不去的直接原因。
- 两个数据集的测试集标签分布与训练/开发集基本一致，未见明显分布漂移。
- 所有样本的文本均含 \$T\$ 占位符，目标以第二序列形式输入，这保证了目标信息在文本侧不会缺失；但目标在图像中是否出现并未被约束（Yu 和 Jiang, 2019 的标注也指出部分目标不出现在图中），这是数据本身对“多模态”定义的一个局限。

6 复现性讨论

6.1 官方代码的工程问题

在逐行核查与冒烟验证中，我们发现以下影响复现的工程问题（详见 `repro/README.md`）：

1. **硬编码路径**：`run_data_analysis.py` 中图片目录写死为 `/root/RethinkingTMSC/...`，不在该路径下运行必然失败；复现脚本已自动替换为仓库实际路径。
2. **脚本工作目录**：`README` 的 `cd scripts && bash run.sh` 与脚本内相对路径矛盾，应在仓库根目录执行 `bash scripts/run.sh`。
3. **权重路径**：`--resnet_root` 默认 `./resnet` 与 `README` 要求的 `Code/resnet/` 不一致，且代码固定读取文件名 `resnet152.pth`，需显式传参并正确命名。
4. **依赖缺失**：`requirements.txt` 中的 `apex`、`modeling` 在 PyPI 上不存在；`apex` 有 fallback（本文冒烟验证即证明无 `apex` 可运行），已从依赖中移除。
5. **Faster* 模型**：需 Faster R-CNN 预训练权重（位于 `Code/faster_rcnn/models/faster_rcnn_res101_vg.pth`）及 CUDA 扩展编译；若编译失败，可用 `MODELS` 过滤跳过。
6. **图片归属**：官方未提供自动整理脚本；本仓库已用 `data/twitter2015_images/`、`data/twitter2017_images/` 的图片整理完毕并逐张核对，若使用其他来源需自行核对 ImageID。

6.2 服务器复现指南

`repro/` 目录提供了完整的一键式复现包：

```
bash repro/download_assets.sh # 下载图片、ResNet-152、Faster R-CNN 权重
bash repro/setup_env.sh      # 建环境、修路径、编译 faster_rcnn
bash repro/run_all.sh        # 220 次训练（多卡/断点续跑/模型过滤）
python repro/collect_results.py Code/output # 汇总结果 CSV
```

复现完成后，将结果与表 2、表 3 对照：同种子下 F1 偏差在 ± 1 个百分点内可视为复现成功。

7 结论与展望

本文对 RethinkingTMSO 进行了独立的复现实证研究，主要结论如下：

1. 官方代码主链路可运行（冒烟验证通过）；完整训练复现仅受限于算力、图片数据与预训练权重等外部资源，`repro/` 脚本包已就绪。
2. 文本单模态 BERT 已具备很强性能；纯视觉模型远弱于文本模型且存在类别坍塌；多模态融合相对 BERT 的增益普遍不足 1 个 F1 百分点，且部分模型为负增益。
3. 种子随机性影响显著：Faster2Bert 的准确率跨种子极差最高达 17.7 个百分点，单次运行报告不可靠；5 种子多数投票集成在 41/44 个“模型×数据集”组合上不劣于单种子，最高带来 +16.3 个 F1 百分点的提升。
4. 错误集中在负面情感与反讽/隐含表达上；Twitter17 上图像的正向作用更大，与数据层图片共享程度更高一致。

展望方面，我们认为有三个方向值得推进：一是**数据审计与重建**，约束目标在图像中的可见性并扩充负面与反讽样本；二是**更强的目标-图像对齐**（如 CLIP 类跨模态表示、检测框级目标定位），而非仅依赖整体图像特征；三是**评测协议规范化**，统一报告多种子均值±标准差并鼓励公开逐样本预测，以便他人进行本文这类再分析。

参考文献

- [1] Ye J, Zhou J, Tian J, et al. RethinkingTMSC: An Empirical Study for Target-Oriented Multimodal Sentiment Classification[C]. Findings of ACL: EMNLP 2023: 270–277.
- [2] Yu J, Jiang J. Adapting BERT for Target-Oriented Multimodal Sentiment Classification[C]. IJCAI 2019: 5408–5414.
- [3] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]. NAACL-HLT 2019: 4171–4186.
- [4] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]. CVPR 2016: 770–778.
- [5] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale[C]. ICLR 2021.
- [6] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[C]. NeurIPS 2015.
- [7] Zadeh A, Chen M, Poria S, et al. Tensor Fusion Network for Multimodal Sentiment Analysis[C]. EMNLP 2017: 1103–1114.
- [8] Zhang Q, Fu J, Liu X, et al. Adaptive Co-attention Network for Named Entity Recognition in Tweets[C]. AAAI 2018: 5674–5681.
- [9] Lu D, Neves L, Carvalho V, et al. Visual Attention Model for Name Tagging in Multimodal Social Media[C]. ACL 2018: 1990–1999.

A 数据、脚本与复现方法

本文全部结果可由仓库内脚本复现：

- `analysis/collect_results.py`: 汇总 220 组 `eval_results.txt`, 生成 `results_all.csv` 与 `results_summary.csv` (表 2、表 3 数据来源)。
- `analysis/data_stats.py`: 数据集统计 (表 1)。
- `analysis/error_analysis.py`: 逐类指标、投票集成、纠正/恶化、困难样本 (表 4–表 6)。
- `analysis/make_figures.py`: 图 1–图 6。
- `analysis/smoke_test.py`: CPU 冒烟验证 (第 4.2 节)。
- `repro/`: GPU 服务器复现包 (第 6.2 节)。

所有分析脚本使用仓库自带虚拟环境 `TMSC_env` (Python 3.8 + torch 1.10.0+cpu + transformers 4.22.1) 运行, 不依赖外部下载。